

Q. (우리 프로젝트의, 온톨로지를 기반하는)RAG 시스템을 어떻게 평가할것인가?

+KPI를 무엇으로 잡을것인가 +RAG Assesment dataset을 어디서 끌어올것인가 (혹은 제작해야하는가?) +예지보전 (우리 도메인) RAG 에 대해서 어떤점을 고려해야하는가 ++방대한양의 manual에 대해 성공적으로 generation을 해낼 수 있는가

Key Point 1 : 보편적인 RAG KPI (예시)

- 1. **MTTR(장애 대응 시간)** : 장애 발생 인지부터 원인 파악까지 걸리는 시간을 기존 수동 방식 대비 얼마나 절감했는가 (단축률?)

제조 / 예지보전 / 신속한 사후대처 가 목표인 우리 프로젝트에서 가장 적합한 평가지표가 될거라고 생각함

다만 '단축률'을 보기 위해서는 기존에 존재하는 시스템 비교군이 필요할듯. 구축할 RAG 시스템의 MTTR, MTTF, MTBF 등은 (TruLens)를 통해 쉽게 구할 수 있음

관련 내용은 뒤에 자세하게 정리 ㄱㄱ

- 2. **알림 피로도 감소**: 유의미한 이상 징후만 선별 통보하여 과도한 오알람과 알림 피로도를 얼마나 낮추었는가

유의미한 지표가 될수도 있겠으나 역시 비교를 위해서 '기존시스템'의 latency등의 지표가 필요하나 확보하는데에 어려움이 있을것같음

- 3. 리포트 가독성 및 생산성 향상: 자동 생성된 리포트나 Slack 메시지를 통해 작업자가 즉시 복구 및 수정 작업에 집중할 수 있었는가

본 프로젝트에서는 정량적으로 구하기 어려울것이기에 일단은 백로그로

Key Point 2 : Framework

1. RAGAS (프로토타입/평가용)

Pandas 기반으로 모델의 답변 결과를 오프라인에서 정량적으로 채점하는 데 특화

Pros

- 제조업에 필수적인 엄격한 환각 검증: 공장 설비 매뉴얼을 다루는 만큼 hallucination을 막는 것이 가장 중요한데 RAGAS가 특화되어있음
- 가벼운 파이프라인 결합: 별도의 서버나 UI 창을 띄울 필요 없이 Python 스크립트 내에서 질문가능 검색된 문서, 생성된 답변을 표 형태로 밀어 넣으면 점수가 바로 산출되므로 초기 연구/실험단계에서 가볍게 쓸 수 있음

Cons

- 시각적 대시보드 부재: 시스템의 실시간 흐름을 보여주는 UI가 없음 E2E 파이프라인의 전체적인 동작 과정을 멘토나 팀원들에게 시각적으로 보여주기에는 불리
- 최종 운영 모니터링 한계: 개발 과정에서의 '성능 평가'에는 훌륭하지만 실제 슬랙 알림이 지속적으로 발송되는 운영 환경에서 시스템이 잘 돌고 있는지 추적하는 기능은 부족

2. TruLens (모니터링 대시보드)

평가 지표 산출부터 LLM 애플리케이션의 동작 과정을 웹 UI를 통해 실시간추적, 시각화

Pros

- **파이프라인 시각화에 최적:** 센서 데이터 입력부터 AI의 이상 감지, 매뉴얼 검색, 최종 출력까지 이어지는 전체 흐름을 앱 형태로 추적함 웹 대시보드를 통해 "E01 에러 감지 시 어떤 프롬프트를 탔고 어떤 문서를 가져왔는지"를 한눈에 증명할 수 있음 >> 포트폴리오 발표 시 **설명력**, tied to XAI
- **비용 및 지연 시간 추적:** 단순한 답변 정확도를 넘어 RAG 리포트를 하나 생성할 때마다 걸리는 시간과 토큰 비용을 대시보드에 기록가능 **신뢰성, 가용성, 보전성등 정통적 운영관리지표 관리하기 좋음**

Cons

- **무거운 초기 세팅:** RAGAS와 달리 로컬 DB를 세팅하고 백그라운드에서 웹 서버를 띄워야 하므로 초기 코드 작성 시 프레임워크 자체를 학습하고 파이프라인 코드에 래핑하는 작업이 번거로울수도
- **오버헤드:** 시스템이 동작할 때마다 평가와 로깅을 동시에 수행하므로 코드가 다소 무거워지고 실행 시간이 길어질 수 있음

3. (이상적) 결론

1. 초기엔 **RAGAS** Vector DB에 E01~E04 case에 대한 (혹은 구해온 manual) 정비 지침서를 처음 밀어 넣고 LLM이 헛소리(환각) 없이 정확하게 답변을 생성하는지 프롬프트를 튜닝하며 성능을 끌어올린 뒤

2. 실제 **serving**은 **TruLens**를 통해 단순한 RAG 성능 튜닝을 넘어 센서에서 이상 징후가 포착되었을 때 자동 필터링을 거쳐 처리하도록 이식하는것이 이상적일것 같다.

Key Point 3 : RAG Assesment Dataset 수급방안

1. 공공 벤치마크 데이터셋 (일반 QA/검색 평가용)

- **특징:** 일반적인 상식, 뉴스, 위키피디아 기반 질문과 정답 세트로 구성되어 있다 RAG 평가 프레임워크의 기본 동작을 테스트할 때 쓸 수 있지만 도메인 특화 프로젝트의 평가용으로는 부적합 (종류는 뒤에 참고)

2. LLM 기반 합성 데이터 자동 생성 (Synthetic Data Generation)

- **종류:** **RAGAS**의 **Testset Generator** 또는 **LangChain/LlamaIndex**의 합성 데이터 생성 기능
- **특징:** 프로젝트가 보유한 매뉴얼 텍스트 문서를 LLM에 밀어 넣으면 문맥을 분석하여 가상의 question-ground truth 쌍을 자동으로 수십~수백 건 생성해 줌

3. 자체 매뉴얼 기반 Dataset 직접 수동 구축

- **특징:** 개발자나 현업 정비 전문가가 주요 장애 시나리오별로 질문과 모범 정답 리포트를 직접 작성하는 방식
- 품이 들고 데이터 개수는 적더라도 평가의 정확성과 신뢰도가 가장 높음
- 본 프로젝트는 **RSW 설비의 에러 코드와 센서 이상 시그널**을 다루는 특수한 B2B/제조 도메인이므로 외부 공공 데이터셋(1)은 사용할 수 없으며 다음과 같이 '**합성 생성(2) + 직접 수거(3)**' 방식을 혼합한 전용 데이터셋을 구성해야 할것이다.

우리 시스템 평가 데이터셋의 4대 핵심 구성 항목

RAGAS나 TruLens에 주입할 데이터프레임은 다음 항목으로 구성되어야 한다

1. Question (입력 질문 / 이상 시그널 컨텍스트):

- 예: "E01 에러 감지: 카운터밸런스 보상 압력이 1800ms 동안 목표 수치에 도달하지 못함. 현재 c5 압력 수치 이상 발생."

2. Contexts (검색된 매뉴얼 단락):

- Vector DB에서 가져온 E01 조치 지침서 단락 텍스트

3. Answer (RAG 파이프라인이 생성한 리포트):

- LLM의 최종 출력 or 리포트

4. Ground Truth (이상적인 모범 정답):

- 정비 매뉴얼 기반으로 작성된 완벽한 원인 분석 및 수정 조치 가이드 문장.

데이터셋 구축 프로세스

1. 매뉴얼 텍스트 준비:

- E01-04 각각의 원인과 조치 절차가 담긴 사내 정비 지침서 마련

2. LLM 합성 생성으로 기본 데이터 확보 (1차)

- RAGAS의 **Testset Generator**를 활용해 준비된 E01~E04 매뉴얼 문서를 바탕으로 질문-정답 세트 20~30개를 자동으로 1차 추출

3. 핵심 시나리오 수동 검수 및 최종 정제 (2차):

- E01~E04 핵심 장애 시나리오별로 최소 5건씩, 적어도 20~30건의 고품질 평가 세트(Golden Dataset)로 수작업 정제

RAGAS-Testset Generator

1. 작동 매커니즘

- **문서 분할 및 분석:** 입력된 매뉴얼을 청킹하고 각 단락에서 중요한 키워드와 개념 추출
- **지식 관계망 구축 (Ontology):** 추출된 개념들 간의 물리적, 논리적 관계를 분석하여 문서 내용에 대한 내부적인 지식 그래프를 만듦
- **질문 생성 및 진화:** 구축된 지식을 바탕으로 생성용 LLM이 가상의 질문들을 만들어냅니다. 단순한 질문에서 시작해 복잡도를 점진적으로 높여가는 일종의 진화과정을 거침
- **정답 및 문맥 매핑:** 만들어진 질문에 완벽하게 부합하는 이상적인 정답을 생성하고 정답의 근거가 된 실제 매뉴얼 단락을 짝지어 최종 데이터셋을 완성

2. 생성하는 질문의 난이도 유형 단순한 텍스트 매칭이 아닌 RAG 파이프라인의 실질적인 추론 능력을 평가하기 위해 다음과 같이 다양한 유형의 질문을 섞어서 생성함

- **단순 질문 (Simple):** 특정 단락의 사실을 그대로 묻는 직관적인 질문
 - (예: "E01 에러를 판정하는 기준 시간은 몇 ms인가?"

- **추론 질문 (Reasoning):** 문서의 내용을 바탕으로 논리적 인과관계를 묻는 질문
 - 예: "c5 압력이 목표치에 도달하지 못했을 때, 가장 먼저 확인해야 할 센서는 무엇인가?"
- **다중 문맥 질문 (Multi-context):** 여러 단락이나 서로 다른 페이지에 흩어진 정보를 종합해야만 대답할 수 있는 질문입니다.
 - 예: "E01(압력 부족)과 E02(전극 파손) 에러 발생 시 공통적으로 적용할 수 있는 안전 조치는 무엇인가?"

사전 배경지식) RAG를 평가하는 기준

1. 검색성능 평가 (Retrieval) / 문맥의 타당성

- 문맥 관련성 (Relevance): 발생한 이상 시그널(ex, E01)과 관련이 있는 정비 지침서 혹은 해당 부분만 정확하게 검색했는가
- 문맥 정밀도 (Precision): 검색된 문서 리스트 중 정답에 해당하는 핵심 매뉴얼의 중요도가 올바르게 평가되었는가
- 문맥 재현율 (Recall): 특정 에러를 해결하는 데 필요한 모든 매뉴얼과 절차를 누락 없이 가져왔는가

2. 생성성능 평가 (Generation) / 결과물 퀄리티

- 사실성/충실성 (Faithfulness): LLM이 생성한 조치 가이드가 검색된 사내 정비 지침서 내용에만 근거하는가, hallucination이 없는가
- 답변 관련성 (Relevance): 최종 생성된 리포트가 이상 감지 시그널에 대한 원인 분석 및 수정 조치 방향을 묻는 본래 목적에 부합하게 생성되었나

기타1) 산업공학 도메인 : 운영관리 (+Operation Research)

1. MTTR (장애 평균 복구 시간): 프로젝트의 핵심 KPI

- **기존의 문제 (문제정의):** 기존에는 시스템 이상 징후 발생 시 담당 개발자나 작업자가 복잡한 서버 메트릭 그래프와 수만 줄의 에러 로그를 수동으로 일일이 조회하느라 장애 원인 파악(MTTR) 시간이 심각하게 지연된다
- **RAG의 기여:** LLM 기반 RAG가 에러에 부합하는 사내 정비 지침서를 즉시 검색해 요약 리포트 혹은 알람을 발생시켜 작업자는 원인 분석 건너뛰고 바로 수정 조치에 돌입할 수 있게되므로 **장애 인지부터 복구까지의 MTTR을 단축**시킬 수 있다는 접근 - TruLens를 통해 Latency, 선제적알림(csv파일 내 타겟값) 만 추적하면 구할 수 있음

2. MTBF (평균 무고장 시간): 예측 유지보수의 가치 증명

- **기존의 문제 (문제정의):** 고장이 터진 후에야 고치는 사후 정비 방식으로는 예기치 않은 가동 중단을 막을 수 없어 전체 공정의 효율이 떨어질 것이다.
- **RAG의 기여:** 모델이 E01~E04라는 치명적 고장으로 파멸하기 전 E016이나 E028 같은 자잘한 경고 로그들을 전조 증상으로 미리 포착하여 RAG 알람을 발생시킨다. 작업자가 기계가 멈추기 전에 RAG 가이드를 보고 미리 윤활유를 보충하거나 영점을 맞추면 **기계가 멈추는 치명적 고장 주기를 늘려 MTBF를 극대화**할 수 있게될것이다.

3. MTTF (평균 고장 시간): 소모성 부품수명 관리

- **RAG의 기여:** RAG 시스템이 매뉴얼에 근거해 마찰력이나 압력의 미세한 이상 패턴을 짚어주며 "현재 상태에서 마모를 늦추기 위한 조치"를 가이드할 수 있다. 예를 들어 E02(전극 파손)와 같은 부품의 파국적 손상을 늦추어 **핵심 소모품의 실질적인 수명(MTTF) 연장에 기여**한다고 볼수있다.

기타2) 평가지표 참고 (수식적인 부분)

1. 문맥 정밀도

- **의미:** 검색된 정비 지침서 중 정답에 해당하는 핵심 매뉴얼이 상위에 잘 랭크되었는지를 0~1 사이의 값으로 산출합니다.
- **산출 수식 (MAP@K 활용):**

$$\text{Context Precision@K} = \frac{\sum_{k=1}^K (\text{Precision@}k \times v_k)}{\text{관련 있는 총 매뉴얼 수}}$$

- **작동 원리:** K 는 검색된 문서의 순위입니다. v_k 는 k 번째 문서가 실제 관련이 있으면 1, 아니면 0을 부여하는 지시 함수(Indicator function)입니다. 예를 들어 E01(카운터밸런스 시간 초과) 시그널이 발생했을 때, E01 조치 매뉴얼이 1순위로 검색되면 높은 점수를 받지만, 3순위나 4순위로 밀려나면 점수가 페널티를 받아 크게 깎이게 됩니다.

2. 문맥 재현율 (Context Recall)

- **의미:** 완벽한 조치를 위해 필요한 정답(Ground Truth) 정보가 검색된 매뉴얼 안에 누락 없이 얼마나 포함되었는지 계산합니다.
- **산출 수식:**

$$\text{Context Recall} = \frac{|\text{검색된 매뉴얼 내용에 포함된 정답(Ground Truth) 문장 수}|}{|\text{정답(Ground Truth)의 총 문장 수}|}$$

- **작동 원리:** 심판 역할을 하는 LLM이 사전 구축된 이상적인 '정답 리포트'를 여러 개의 문장(Statements)으로 쪼갭니다. 그런 다음, 검색해 온 문서들을 읽고 정답의 각 문장 내용이 문서 안에 존재하는지(True/False) 매핑하여 비율을 계산합니다.

3. 사실성 및 충실성 (Faithfulness)

- **의미:** 모델이 검색된 매뉴얼에 없는 내용을 지어내지 않았는지(환각 현상)를 철저히 검증하여 0~1 사이로 수치화합니다.
- **산출 수식:**

$$\text{Faithfulness} = \frac{|\text{검색된 매뉴얼(Context)로 증명 가능한 답변 내 주장(Claim) 수}|}{|\text{답변에서 추출된 총 주장(Claim) 수}|}$$

- **작동 원리:**
 1. 평가용 LLM이 최종 생성된 리포트에서 개별 주장(Claim)들을 추출합니다. (예: "카운터밸런스의 압력을 확인해야 한다", "센서를 교체해야 한다" 등)
 2. 각 주장이 검색된 문서 내용으로 뒷받침(Entailment)되는지 검사합니다. 만약 검색된 매뉴얼에 "센서 교체"라는 말이 없는데 LLM이 리포트에 적었다면 분자가 줄어들어 점수가 깎입니다.

4. 답변 관련성 (Answer Relevance)

- **의미:** 생성된 리포트가 애초에 감지된 에러(예: E01, E02 등)에 대한 원인과 조치 방법을 묻는 본래의 목적에 얼마나 부합하는지 임베딩 공간에서 계산합니다.
- **산출 수식 (코사인 유사도 활용):**

$$\text{Answer Relevance} = \frac{1}{N} \sum_{i=1}^N \cos(E(q), E(q_i))$$

- **작동 원리:**

1. 생성된 리포트를 바탕으로 평가용 LLM이 역으로 N 개의 '가상의 질문(q_i)'을 생성합니다.
2. 임베딩 모델(E)을 사용해 원래의 실제 질문/시그널(q)과 가상의 질문들(q_i)을 벡터로 변환합니다.
3. 이 벡터들 간의 코사인 유사도(Cosine Similarity)를 평균 내어 점수를 산출합니다. 원래의 목적에 맞게 답을 썼다면, 역으로 생성한 질문도 원래 질문과 벡터 공간상에서 매우 가까울 것이라는 원리를 이용한 정량화 기법입니다.

기타3) RAG 공공 벤치마크 데이터셋

- MS MARCO

- 마이크로소프트에서 공개한 대규모 기계 독해 및 답러닝 검색 연구용 데이터셋입니다. 실제 Bing 검색 엔진의 로그를 기반으로 구축
- **질의응답:** 실제 사용자가 검색한 질문과 사람이 직접 작성한 답변을 포함합니다
- **패시지 랭킹:** 질문에 가장 알맞은 문서를 찾아 순위를 매기는 모델 학습에 쓰입니다.
- **연구 활용:** 인공지능이 문맥을 이해하고 정답을 찾아내는 자연어 처리(NLP) 성능 평가에 널리 사용됩니다

- SQuAD

- 컴퓨터가 지문을 읽고 질문에 답하도록 훈련하고 평가하는 기계 독해(MRC) 벤치마크 데이터셋
- **정의:** 스탠퍼드 대학에서 구축한 대규모 질의응답(QA) 데이터셋입니다.
- **구성 요소:** 위키피디아 문서의 **지문**, 이에 대한 **질문**, 그리고 지문 내에 존재하는 ****정답**으로 이루어져 있습니다.
- **목적:** AI 모델이 문맥을 정확히 이해하고 정답 텍스트와 위치를 찾아내는지 객관적으로 평가합니다

- HotpotQA

- 복수의 문서(멀티홉, Multi-hop)를 탐색하고 추론해야 답을 구할 수 있는 113,000개의 위키피디아 기반 질의응답 데이터셋
- **멀티홉 추론:** 정답을 찾기 위해 최소 두 개 이상의 서로 다른 문서나 단락을 연결해서 읽고 추론해야 합니다.
- **문장 수준의 근거 제공:** 모델이 어떤 문장을 근거로 추론했는지 문장 단위의 정답 레이블(Supervision)을 제공하여 설명 가능한 AI 연구를 지원합니다.
- **다양한 질문 유형:** 기존 지식 베이스 스키마에 구애받지 않으며, 두 엔티티를 비교하는 팩토이드 비교 질문 등을 포함

- BEIR

- 다양한 도메인과 작업에서 정보 검색(IR) 모델의 **제로샷 성능과 일반화 능력을 평가**하기 위해 만들어진 이질적인 벤치마크 데이터셋 모음
- **제로샷 평가:** 학습 데이터를 제공하지 않고, 곧바로 다양한 도메인에 적용해 성능을 측정합니다.
- **다양한 구성:** 9개의 서로 다른 검색 작업과 18개의 공공 데이터셋을 포함하고 있습니다.